

**ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ АВТОНОМНОЕ
ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ
ИТМО**

**Лабораторная работа
По предмету Функциональный Анализ**

Кейсы 1 и 7

Выполнила:

Сидельникова Дарья, 476010

Группа:

J3211

Санкт-Петербург, 2026

Аннотация

В работе рассматриваются два кейса: первый связан со спектральным анализом интегрального оператора с ядром $K(x, t) = \min(x, t)$ на отрезке $[0, 1]$. Второй посвящен построению и анализу аддитивных регрессионных моделей, в которых линейные вклады признаков заменяются одномерными нелинейными компонентами.

Содержание

Содержание

1 Кейс 1. Спектральная задача для интегрального оператора	3
1.1 Постановка задачи	3
1.2 Аналитическое решение	3
1.3 Численная схема	4
1.4 Ошибки	6
1.5 Проверка матрицы Грама	6
1.6 Сравнение точного и численного спектра	7
1.7 Сходимость по числу узлов	9
1.8 Спектральное восстановление ядра	10
1.9 Итог по кейсу 1	12
2 Кейс 7. Аддитивные модели регрессии	13
2.1 Постановка задачи	13
2.2 Базисное представление	13
2.3 Центрирование компонент	14
2.4 Метрики качества	15
2.5 Синтетические аддитивные данные	15
2.6 Данные с взаимодействием признаков	17
2.7 Итог по кейсу 7	20
3 Вывод	21
4 Политика использования ИИ	21

1 Кейс 1. Спектральная задача для интегрального оператора

1.1 Постановка задачи

Я рассматриваю интегральный оператор

$$(Tf)(x) = \int_0^1 K(x, t)f(t) dt, \quad K(x, t) = \min(x, t), \quad x, t \in [0, 1]. \quad (1)$$

Основная задача состоит в численном решении спектрального уравнения

$$T\varphi = \lambda\varphi, \quad (2)$$

то есть

$$\int_0^1 \min(x, t)\varphi(t) dt = \lambda\varphi(x). \quad (3)$$

Ядро симметрично:

$$K(x, t) = K(t, x). \quad (4)$$

Также оно неотрицательно определено, поскольку

$$K(x, t) = \mathbb{E}[W(x)W(t)] \quad (5)$$

для винеровского процесса $W(t)$. Поэтому для любой сетки $x_0, \dots, x_{n-1}$ матрица Грама

$$G_{ij} = K(x_i, x_j) = \min(x_i, x_j) \quad (6)$$

должна удовлетворять условию

$$z^T G z = \sum_{i=0}^{n-1} \sum_{j=0}^{n-1} z_i G_{ij} z_j \geq 0. \quad (7)$$

1.2 Аналитическое решение

Для оператора с ядром $K(x, t) = \min(x, t)$ известен точный спектр:

$$\lambda_k = \frac{1}{\pi^2(k - \frac{1}{2})^2}, \quad k = 1, 2, \dots, \quad (8)$$

$$\varphi_k(x) = \sqrt{2} \sin \left((k - \frac{1}{2})\pi x \right). \quad (9)$$

Эти функции ортонормированы в $L^2[0, 1]$:

$$\langle \varphi_i, \varphi_j \rangle = \int_0^1 \varphi_i(x) \varphi_j(x) dx = \delta_{ij}. \quad (10)$$

Для вывода краевой задачи я раскладываю интеграл:

$$\int_0^1 \min(x, t) \varphi(t) dt = \int_0^x t \varphi(t) dt + x \int_x^1 \varphi(t) dt. \quad (11)$$

Обозначаю

$$F(x) = \int_0^1 \min(x, t) \varphi(t) dt. \quad (12)$$

Тогда

$$F'(x) = \int_x^1 \varphi(t) dt, \quad F''(x) = -\varphi(x). \quad (13)$$

Так как $F(x) = \lambda \varphi(x)$, получаю

$$\lambda \varphi''(x) + \varphi(x) = 0. \quad (14)$$

Краевые условия:

$$\varphi(0) = 0, \quad \varphi'(1) = 0. \quad (15)$$

Итоговая краевая задача:

$$\begin{cases} \lambda \varphi''(x) + \varphi(x) = 0, \\ \varphi(0) = 0, \\ \varphi'(1) = 0. \end{cases} \quad (16)$$

1.3 Численная схема

Я заменяю отрезок $[0, 1]$ равномерной сеткой:

$$x_i = \frac{i}{n-1}, \quad i = 0, 1, \dots, n-1, \quad h = \frac{1}{n-1}. \quad (17)$$

Интеграл заменяю квадратурной суммой:

$$\int_0^1 f(t) dt \approx \sum_{j=0}^{n-1} w_j f(x_j). \quad (18)$$

В работе я использую три варианта весов.

Для метода прямоугольников:

$$w_j = \frac{1}{n}. \quad (19)$$

Для метода трапеций:

$$w_0 = w_{n-1} = \frac{h}{2}, \quad w_j = h, \quad j = 1, \dots, n-2. \quad (20)$$

Для метода Симпсона:

$$w = \frac{h}{3}(1, 4, 2, 4, 2, \dots, 4, 1). \quad (21)$$

После дискретизации получаю матричную задачу:

$$\sum_{j=0}^{n-1} K(x_i, x_j) w_j \varphi(x_j) = \lambda \varphi(x_i). \quad (22)$$

Матрица оператора:

$$A_{ij} = K(x_i, x_j) w_j. \quad (23)$$

Так как матрица A не является симметричной при неравных весах, я перехожу к подобной симметричной матрице:

$$B = W^{1/2} K W^{1/2}, \quad W = \text{diag}(w_0, \dots, w_{n-1}). \quad (24)$$

Если

$$Bu = \lambda u, \quad (25)$$

то численная собственная функция восстанавливается как

$$\varphi_i = \frac{u_i}{\sqrt{w_i}}. \quad (26)$$

Нормировку я выполняю по дискретной L^2 -норме:

$$\|\varphi\|_w = \left(\sum_{j=0}^{n-1} \varphi^2(x_j) w_j \right)^{1/2}. \quad (27)$$

1.4 Ошибки

Ошибка собственного значения:

$$e_k^{(\lambda)} = |\lambda_k^{num} - \lambda_k^{exact}|. \quad (28)$$

Ошибка собственной функции:

$$e_k^{(\varphi)} = \left(\sum_{j=0}^{n-1} |\varphi_k^{num}(x_j) - \varphi_k^{exact}(x_j)|^2 w_j \right)^{1/2}. \quad (29)$$

Так как собственная функция определена с точностью до знака, я также учитываю эквивалентность

$$\varphi_k(x) \sim -\varphi_k(x). \quad (30)$$

Поэтому при необходимости знак численного собственного вектора можно заменить:

$$\varphi_k^{num} \leftarrow -\varphi_k^{num}. \quad (31)$$

1.5 Проверка матрицы Грама

Для сетки из 50 узлов я построила матрицу

$$G_{ij} = \min(x_i, x_j). \quad (32)$$

Численно проверялись два условия:

$$\max_{i,j} |G_{ij} - G_{ji}| = 0, \quad (33)$$

$$\lambda_{\min}(G) \geq 0. \quad (34)$$

Также я проверяла случайные квадратичные формы:

$$q(z) = z^T G z. \quad (35)$$

Минимальное значение среди случайных проверок оказалось положительным:

$$\min q(z) = 1.195092. \quad (36)$$

Следовательно, численный результат согласуется с теорией: ядро задаёт симметричную положительно полуопределённую матрицу.

1.6 Сравнение точного и численного спектра

Для $n = 101$ и метода трапеций я получила следующие значения.

Таблица 1: Сравнение точных и численных собственных значений при $n = 101$.

k	λ_k^{exact}	λ_k^{num}	$e_k^{(\lambda)}$
1	0.405285	0.405293	0.000008
2	0.045032	0.045040	0.000008
3	0.016211	0.016220	0.000008
4	0.008271	0.008279	0.000008
5	0.005004	0.005012	0.000008
6	0.003349	0.003358	0.000008

Вывод по таблице: ошибка первых собственных значений имеет порядок 10^{-6} – 10^{-5} , поэтому дискретизация хорошо приближает аналитический спектр.




Рис. 1: Аналитические и численные собственные функции.

Вывод по рисунку 1: численные функции повторяют форму аналитических. Возможное отличие знаком не является ошибкой, так как φ и

$-\varphi$ задают одну собственную пару.

1.7 Сходимость по числу узлов

Я сравнила ошибки для сеток

$$n \in \{21, 51, 101, 201\}. \quad (37)$$

Таблица 2: Абсолютная ошибка первых собственных значений при разных n .

n	e_1	e_2	e_3	e_4	e_5
21	$2.08 \cdot 10^{-4}$	$2.09 \cdot 10^{-4}$	$2.10 \cdot 10^{-4}$	$2.12 \cdot 10^{-4}$	$2.14 \cdot 10^{-4}$
51	$3.30 \cdot 10^{-5}$	$3.30 \cdot 10^{-5}$	$3.30 \cdot 10^{-5}$	$3.30 \cdot 10^{-5}$	$3.30 \cdot 10^{-5}$
101	$8.00 \cdot 10^{-6}$	$8.00 \cdot 10^{-6}$	$8.00 \cdot 10^{-6}$	$8.00 \cdot 10^{-6}$	$8.00 \cdot 10^{-6}$
201	$2.00 \cdot 10^{-6}$	$2.00 \cdot 10^{-6}$	$2.00 \cdot 10^{-6}$	$2.00 \cdot 10^{-6}$	$2.00 \cdot 10^{-6}$

При измельчении сетки ошибка убывает:

$$n \uparrow \Rightarrow h = \frac{1}{n-1} \downarrow \Rightarrow e_k^{(\lambda)} \downarrow. \quad (38)$$




Рис. 2: Сходимость ошибки собственных значений при увеличении числа узлов.

Вывод по рисунку 2: на логарифмической шкале ошибка монотонно уменьшается. Это подтверждает сходимость численной схемы.

1.8 Спектральное восстановление ядра

Я также проверила усечённое спектральное разложение:

$$K(x, t) = \sum_{k=1}^{\infty} \lambda_k \varphi_k(x) \varphi_k(t). \quad (39)$$

Численно используется конечная сумма:

$$K_m(x, t) = \sum_{k=1}^m \lambda_k \varphi_k(x) \varphi_k(t). \quad (40)$$

Ошибка измеряется нормой Фробениуса:

$$\|K - K_m\|_F = \left(\sum_{i=0}^{n-1} \sum_{j=0}^{n-1} |K_{ij} - K_{m,ij}|^2 \right)^{1/2}. \quad (41)$$

Таблица 3: Ошибка усечённого спектрального разложения ядра.

m	$\ K - K_m\ _F$
1	4.912450
2	1.959988
5	0.521801
10	0.189373
20	0.071702
40	0.030596

Ошибка убывает:

$$m \uparrow \Rightarrow \|K - K_m\|_F \downarrow. \quad (42)$$




Рис. 3: Точное ядро $K(x, t) = \min(x, t)$.

Вывод по рисунку 3: матрица ядра симметрична относительно главной диагонали. Значения возрастают при увеличении x и t , что соответствует формуле $\min(x, t)$.




Рис. 4: Спектральная аппроксимация ядра при $m = 10$.

Вывод по рисунку 4: уже при $m = 10$ восстановленная структура ядра близка к точной. Основной вклад дают первые собственные значения, потому что

$$\lambda_k = \frac{1}{\pi^2(k - \frac{1}{2})^2} \sim \frac{1}{k^2}. \quad (43)$$

1.9 Итог по кейсу 1

В первом кейсе я получила:

$$\max_{i,j} |G_{ij} - G_{ji}| = 0, \quad (44)$$

$$\lambda_{\min}(G) \geq 0, \quad (45)$$

$$e_k^{(\lambda)} \rightarrow 0 \quad \text{при} \quad n \rightarrow \infty, \quad (46)$$

$$\|K - K_m\|_F \rightarrow 0 \quad \text{при} \quad m \rightarrow \infty. \quad (47)$$

Следовательно, построенная дискретизация корректно воспроизводит спектральные свойства интегрального оператора.

2 Кейс 7. Аддитивные модели регрессии

2.1 Постановка задачи

Я рассматриваю задачу регрессии:

$$y_i = f(x_i) + \varepsilon_i, \quad i = 1, \dots, N. \quad (48)$$

Для вектора признаков

$$x_i = (x_{i1}, x_{i2}, \dots, x_{ip}) \quad (49)$$

линейная модель имеет вид

$$\hat{y}_i = \beta_0 + \sum_{j=1}^p \beta_j x_{ij}. \quad (50)$$

Её ограничение состоит в том, что

$$\frac{\partial^2 \hat{y}}{\partial x_j^2} = 0. \quad (51)$$

Поэтому линейная модель не описывает нелинейный вклад отдельного признака.

Аддитивная модель задаётся формулой

$$\hat{y}_i = \beta_0 + \sum_{j=1}^p g_j(x_{ij}). \quad (52)$$

Здесь каждая функция g_j отвечает за вклад одного признака.

2.2 Базисное представление

Я приближаю каждую компоненту g_j конечным базисным разложением:

$$g_j(x) = \sum_{m=1}^M \theta_{jm} b_m(x). \quad (53)$$

Тогда модель принимает вид

$$\hat{y}_i = \beta_0 + \sum_{j=1}^p \sum_{m=1}^M \theta_{jm} b_m(x_{ij}). \quad (54)$$

Если обозначить матрицу базисных признаков через Φ , то

$$\hat{y} = \Phi\theta. \quad (55)$$

Метод наименьших квадратов:

$$\hat{\theta} = \arg \min_{\theta} \|y - \Phi\theta\|_2^2. \quad (56)$$

Если матрица $\Phi^T\Phi$ обратима, то

$$\hat{\theta} = (\Phi^T\Phi)^{-1}\Phi^Ty. \quad (57)$$

Для ridge-регрессии:

$$\hat{\theta}_{\alpha} = \arg \min_{\theta} (\|y - \Phi\theta\|_2^2 + \alpha\|\theta\|_2^2). \quad (58)$$

Решение ridge-задачи:

$$\hat{\theta}_{\alpha} = (\Phi^T\Phi + \alpha I)^{-1}\Phi^Ty. \quad (59)$$

2.3 Центрирование компонент

Аддитивное разложение неоднозначно, потому что можно прибавить константу к одной компоненте и вычесть её из свободного члена:

$$\beta_0 + g_j(x) = (\beta_0 + c) + (g_j(x) - c). \quad (60)$$

Поэтому я центрирую компоненты:

$$\frac{1}{N} \sum_{i=1}^N g_j(x_{ij}) = 0. \quad (61)$$

Тогда свободный член равен среднему уровню прогноза:

$$\beta_0 \approx \bar{y}. \quad (62)$$

А сама модель становится интерпретируемой:

$$\hat{y}_i - \beta_0 = \sum_{j=1}^p g_j(x_{ij}). \quad (63)$$

2.4 Метрики качества

Я использую три метрики:

$$\text{MSE} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2, \quad (64)$$

$$\text{RMSE} = \sqrt{\text{MSE}}, \quad (65)$$

$$R^2 = 1 - \frac{\sum_{i=1}^N (y_i - \hat{y}_i)^2}{\sum_{i=1}^N (y_i - \bar{y})^2}. \quad (66)$$

Чем меньше RMSE и чем ближе R^2 к единице, тем лучше модель.

2.5 Синтетические аддитивные данные

Я проверяю модель на данных вида

$$y = f_1(x_1) + f_2(x_2) + \varepsilon. \quad (67)$$

В общем виде аддитивная структура выглядит так:

$$f(x_1, x_2) = g_1(x_1) + g_2(x_2). \quad (68)$$

Именно такую структуру должна хорошо восстанавливать аддитивная модель.

Таблица 4: Сравнение моделей на синтетических аддитивных данных.

Модель	RMSE train	RMSE test	R^2 test
Линейная регрессия	0.7553	0.6985	0.3551
Аддитивная модель, степень 7	0.0982	0.1082	0.9845
Аддитивная ridge-модель, степень 7	0.1056	0.1137	0.9829
Полиномиальная модель, степень 3	0.1884	0.2103	0.9416

Вывод по таблице: аддитивная модель резко улучшает качество по сравнению с линейной регрессией:

$$0.6985 \rightarrow 0.1082 \quad (69)$$

по RMSE на тестовой выборке.

Также

$$R_{linear}^2 = 0.3551, \quad R_{additive}^2 = 0.9845. \quad (70)$$

Значит, нелинейные одномерные компоненты действительно необходимы.




Рис. 5: Синтетические аддитивные данные и восстановленные зависимости.

Вывод по рисунку 5: модель восстанавливает нелинейную форму зависимости. Это подтверждает, что базисное разложение подходит для приближения функций g_j .




Рис. 6: Сравнение качества моделей на аддитивных данных.

Вывод по рисунку 6: линейная модель имеет наибольшую ошибку. Аддитивная модель и ridge-вариант дают лучшие результаты. Полная полиномиальная модель тоже работает хорошо, но хуже интерпретируется.

2.6 Данные с взаимодействием признаков

Далее я рассматриваю случай, где зависимость не является чисто аддитивной:

$$y = f(x_1, x_2) + \varepsilon. \quad (71)$$

Если в функции есть взаимодействие, например

$$f(x_1, x_2) = g_1(x_1) + g_2(x_2) + h(x_1, x_2), \quad (72)$$

то аддитивная модель не может точно восстановить член $h(x_1, x_2)$.

Примеры взаимодействий:

$$h(x_1, x_2) = x_1 x_2, \quad (73)$$

$$h(x_1, x_2) = \sin(2\pi(x_1 + x_2)). \quad (74)$$

Аддитивная модель допускает только сумму:

$$\hat{y} = \beta_0 + g_1(x_1) + g_2(x_2). \quad (75)$$

Но не допускает общий двумерный член:

$$\hat{y} \neq \beta_0 + g_1(x_1) + g_2(x_2) + h(x_1, x_2). \quad (76)$$

Таблица 5: Сравнение моделей на данных с взаимодействием признаков.

Модель	RMSE train	RMSE test	R^2 test
Линейная регрессия	0.5544	0.5688	0.2442
Аддитивная модель, степень 7	0.4813	0.4928	0.4327
Аддитивная ridge-модель, степень 7	0.4814	0.4926	0.4333
Полиномиальная модель, степень 3	0.4822	0.4912	0.4365

На этих данных улучшение есть, но оно ограничено:

$$RMSE_{linear} = 0.5688, \quad RMSE_{additive} = 0.4928. \quad (77)$$

При этом качество остаётся существенно хуже, чем на чисто аддитивных данных:

$$R^2_{additive, additive\ data} = 0.9845, \quad (78)$$

$$R^2_{additive, interaction\ data} = 0.4327. \quad (79)$$




Рис. 7: Данные с взаимодействием признаков.

Вывод по рисунку 7: структура данных сложнее, чем сумма одномерных эффектов. Поэтому аддитивная модель не может полностью описать зависимость.




Рис. 8: Сравнение моделей на данных с взаимодействием признаков.

Вывод по рисунку 8: аддитивная модель лучше линейной, но её преимущество ограничено. Это связано с отсутствием членов вида $h(x_1, x_2)$.

2.7 Итог по кейсу 7

На аддитивных данных я получила:

$$RMSE_{test} = 0.1082, \quad R^2_{test} = 0.9845. \quad (80)$$

На данных с взаимодействием:

$$RMSE_{test} = 0.4928, \quad R^2_{test} = 0.4327. \quad (81)$$

Следовательно,

$$f(x_1, x_2) = g_1(x_1) + g_2(x_2) \quad (82)$$

хорошо описывается аддитивной моделью, а зависимость вида

$$f(x_1, x_2) = g_1(x_1) + g_2(x_2) + h(x_1, x_2) \quad (83)$$

требует более гибкой модели.

3 Вывод

В первом кейсе численная дискретизация интегрального оператора показала согласование с аналитической теорией. Матрица ядра оказалась симметричной и положительно полуопределённой, первые собственные значения совпали с аналитическими с малой ошибкой, а при увеличении числа узлов сетки наблюдалась сходимость. Это подтверждает корректность построения дискретного оператора и вычисления спектра через симметричную матрицу $B = W^{1/2}KW^{1/2}$.

Отдельно следует отметить выбор квадратурной формулы. Метод Симпсона обычно имеет более высокий порядок точности для гладких функций, однако ядро $K(x, t) = \min(x, t)$ имеет излом на линии $x = t$. Из-за этой особенности преимущество более высоких порядков может проявляться слабее, а метод трапеций оказывается устойчивым и достаточно точным для данной задачи.

Во втором кейсе аддитивная модель показала ожидаемое преимущество над линейной регрессией на данных с нелинейными одномерными компонентами. При этом она остаётся более интерпретируемой, чем полная полиномиальная модель. Ограничение аддитивной модели состоит в отсутствии взаимодействий между признаками. Поэтому для зависимостей, где существенны произведения признаков или совместные нелинейные эффекты, требуется использовать более гибкие модели.

4 Политика использования ИИ

При выполнении работы инструменты искусственного интеллекта использовались как вспомогательное средство для структурирования текста, редактирования формулировок и кода в некоторых местах.

Математическая постановка, выбор экспериментов, написание кода, запуск вычислений, анализ результатов и итоговая интерпретация - выполнены мной.

Займствованные идеи и стандартные математические факты не выдаются за мои оригинальные результаты.

Ссылка на репозиторий

GitHub: https://github.com/DariaSide/FunctionalAnalysis_Laboratory/tree/main

Код экспериментов находится в каталоге `src/`